

可验证符号算术轨迹的从零监督训练： 一个小型 Transformer 的初步实验

Primordial Disjunction

2026 年 6 月 26 日

摘要

本文研究一个可控的符号算术生成任务：给定前缀表达式，模型需要生成显式逐步计算轨迹，并输出最终十进制数值。该实验的长期动机是考察 Transformer 是否能够在符号表达式空间和数值空间之间建立可验证的映射，进而为后续的反向符号搜索、beam search verifier 和强化学习式奖励优化提供基础。当前实现训练了一个从零开始的小型 Qwen 风格因果语言模型，仅使用无限在线生成的 **forward** 数据。实验结果显示，在四类浅层算术模板上，模型训练 loss 已降至 10^{-5} 量级，训练内置周期评测在后期连续达到 **forward exact match** 和 **numeric success** 均为 1.0；可视化样例中，模型能够逐 token 复现加法、带负数减法以及进位/借位 trace。与此同时，当前评测样本量较小，尚未验证深度外推、反向索引或 RLHF/RLAIF 设置，因此结论应视为一个可运行的初步正结果，而不是完整的泛化证明。

1 问题设定

原始设想是构造一个可验证的符号搜索任务：

$$v \mapsto e, \quad \text{eval}(e) \approx v,$$

例如从 3.14626 反推出 `add(sqrt(2),sqrt(3))`。这类任务像一个从连续数值到离散语法结构的近似反向索引：若模型成功，它可能学到某种可组合的 hash inverse；若失败，则说明类似 bloom-filter 的记忆机制在符号外推上可能很弱。

当前代码库优先实现并训练了前向可验证任务：

$$e \mapsto (T(e), \text{eval}(e)),$$

其中 e 是表达式， $T(e)$ 是逐步计算 trace。输入为

$$|\text{forward}| + \text{tokens}(e),$$

输出为

$$|\text{beginOfThink}| + T(e) + |\text{endOfThink}| + \text{render}(\text{eval}(e)).$$

2 数据生成

表达式由 `data_generate.py` 在线采样。当前激活的 `forward` 模板如下：

```
add leaf leaf
mul leaf leaf
add neg leaf leaf
add leaf neg leaf
```

叶子常数范围为 $[1, 500]$ ，十进制输出保留 5 位小数。对于 `add`、`mul`、`neg` 以及由负数加法诱导出的 `sub`，生成器会写出结构展开和具体竖式步骤。例如加法 `trace` 会包含：

```
r0 = add r1 r2
r1 = 108
r2 = 107
r0 = add 108 107
    add 108 107
    = addPad 108 107
    = addPos (8 7) (0 0) (1 1)
    = addPosRes (5 1) (0 0) (2 0)
    = addRes 5 (1 0) (0 2) 0
    = addRes 5 1 2 0
    = 0215
    = 215
r0 = 215
```

这样设计的好处是，目标不是黑箱回归一个数字，而是学习一个可检查的算法轨迹。若未来加入 `verifier`，可以分别检查语法合法性、每一行局部计算和最终数值误差。

3 模型与训练

模型为从零训练的 Qwen 风格 decoder-only Transformer。词表由任务 token、运算符、数字、标点和 `trace` token 组成，而不是复用自然语言 tokenizer。主要配置见表 1。

训练采用标准 next-token SFT。prompt 部分 label 置为 -100，只在输出 `trace` 和最终答案上计算交叉熵。训练任务当前仅启用 `forward`，因此 `inverse` 和 `simplify` 的结果不应纳入模型能力结论。

4 实验结果

当前训练日志包含 40,382 条 loss 记录，最后记录步数为 118,565，最后 loss 为 1.91×10^{-5} ，日志中最小 loss 为 2.95×10^{-6} 。内置评测日志在后期每 1000 step 对 2 个 `forward` 样本评测一次；从 109,000 到 118,000 step 的最近 10 次评测中，`forward` exact match rate 和 numeric success rate 均为 1.0，invalid rate 为 0.0。

从 `result/visual.txt` 看，模型在 step 118000 对两个可视化样例均逐 token 完全匹配。第一个样例是 `add(108,107)`，模型正确生成进位步骤并输出 215.00000。第二个样例是 `add(384,neg(416))`，

配置项	数值
词表大小	42
参数量	10,450,304
层数	24
hidden dim	128
attention heads	8
KV heads	2
head dim	64
max sequence length	2304
batch size	4
learning rate	3×10^{-4}
weight decay	0.01

表 1: 当前实验使用的模型与训练配置。

阶段	exact match	numeric success	invalid
step 109000–118000 的周期评测	1.0	1.0	0.0
step 118000 可视化样例	1.0	1.0	0.0

表 2: 当前日志中的 **forward** 初步结果。周期评测每次仅 2 个样本，因此该表说明训练已收敛到可用状态，但不能单独证明大样本泛化。

模型将其规约为 `sub(384,416)`，再翻转为带负号的 `sub(416,384)`，正确处理借位并输出 `-32.00000`。

5 结果怎么看

这个结果是一个清楚的工程正信号：数据格式、tokenizer、长 trace 监督、模型结构和训练循环都已经打通，小模型确实能够学会当前模板分布内的显式算术轨迹。尤其是带负数的样例说明模型不只是输出最终数字，也能复现由生成器规定的中间规约形式。

但从研究结论上还要谨慎。当前 **forward** 样本空间估计为 10^6 ，模板只有 4 个，且评测样本数很小；模型很可能已经在这个受限分布上形成了强模式拟合。原始课题中最有趣的部分，即数值到表达式的反向搜索、深度外推、不同进制比较、beam verifier 和 RLHF/RLAIF 奖励，目前还没有形成实验证据。

6 下一步实验

下一步建议优先补齐三件事。第一，增加独立大样本评测脚本，至少对 **forward** 采样 1,000–10,000 个样本，报告 exact match、numeric success、invalid rate 和按模板分组的错误率。第二，将模板从一层算术扩展到混合表达式，并做 depth split：训练 $\text{depth} \leq 3$ ，测试 $\text{depth} = 4, 5, 6$ 。




图 1: 训练过程保存的 loss 曲线。该图由当前代码库的简易 PNG writer 生成。

第三，重新启用 `inverse`，先用 beam search + verifier 做 top- k success，再考虑基于

$$r(e, v) = -\log(|\text{eval}(e) - v| + \epsilon) - \lambda|e| - \text{invalid penalty}$$

的强化学习或偏好优化。

7 结论

当前项目已经得到一个可信的第一阶段结果：从零训练的小型 Transformer 可以在受控模板上学习可验证的符号算术 trace，并在训练后期的小样本评测中达到完全匹配。这个结果值得作为论文的初步实验写入，但论文主张应限定为“forward trace learning works in a controlled setting”。要支撑更强的“反向符号搜索”或“bloom-filter-like 外推”论断，还需要系统的反向任务、深度外推和大样本评测。